LLM이 좋아져도 남는 검증 아키텍처 v0.4

지원자가 확인한 중요한 진술을 원문부터 최종 한국어 문서까지 연결하고, 의미가 바뀐 지점만 사람에게 검토시키는 구조로 재설계했다.

핵심 판단

DARI의 해자는 더 좋은 검증 모델이 아니다.

모델 밖에 남는 **지원자 확인 claim, evidence, revision, 문항별 contract, 검토 결정**을 연결하는 신뢰 workflow가 핵심이다.

유지

Evidence-linked Case Record

원문, claim, 확인 상태, 수정과 최종 문장을 모델과 독립적으로 유지한다.

조건부

Verifier와 Micrograph

최신 direct baseline보다 잔존 오류나 사람 시간을 줄일 때만 남긴다.

중단

범용 번역 품질 경쟁

번역, graph 추출, self-check 자체를 제품 차별점으로 설명하지 않는다.

첫 검증 범위

confirmed facts → 한국어 초안 → 사용자 수정 → final export

성공 판단

최종 잔존 중요 오류 25% 감소 또는 검수 시간 20% 감소

> **"LLM보다 더 잘 번역한다"가 아니라 "어떤 모델을 쓰더라도 지원자가 확인한 의미가 어디서 바뀌었는지 증명한다."**

01 · STRATEGIC THREAT

사용자의 걱정은 맞다: 모델 기능은 빠르게 평준화된다

빠르게 commodity가 되는 기능

- 다국어 번역과 문서 초안 생성
- 5W1H, claim, graph 추출
- 긴 문단과 문서 전체 입력
- 두 번째 LLM을 이용한 self-check
- on-device 모델 실행 자체
- 종합 quality score와 일반 human review UI

모델이 좋아져도 남을 수 있는 것

- 지원자가 실제로 확인한 의도와 exact evidence
- 한국 신청 문항별 Semantic Contract
- 정정과 철회를 반영한 현재 claim state
- 원문에서 최종본까지 이어지는 revision lineage
- 언어와 위험 유형별 calibration
- 조력자의 검토 책임과 기관 workflow 통합

280×+

GPT-3.5 수준 모델의 추론 비용 하락

Stanford AI Index 2025는 2022년 11월부터 2024년 10월 사이 동등 성능의 질의 비용이 280배 넘게 떨어졌다고 보고한다.[1]

아직

segment와 error span 검출은 불안정

WMT25에서는 큰 LLM이 system 수준에서 강했지만 reference 기반 baseline이 segment 수준에서 앞섰고, 정밀 오류 위치와 precision-recall 균형은 계속 어려웠다.[2]

따라서 연구 가설도 바꾼다

> **"Graph가 번역을 잘 비교하는가?" → "모델과 버전이 바뀌어도 provenance-constrained workflow가 최종 오류와 사람 시간을 줄이는가?"**

설계 원칙

새 모델은 위협인 동시에 더 좋은 부품이다. 생성기, 추출기와 judge를 adapter 뒤에서 교체하고, Evidence-linked Case Record와 검토 결정은 그대로 유지한다. 새 모델은 frozen benchmark와 shadow run을 통과한 뒤에만 승격한다.

[1] Stanford HAI · [2] WMT25

02 · COMPARABLE SERVICES

해외 사례가 보여주는 시장의 빈칸

기존 서비스는 언어 접근, 정보 제공, intake, 문서 조립, case management와 법률 검색을 각각 잘 해결한다. DARI는 그 전체를 다시 만들기보다 변환 과정의 의미 무결성 층을 맡아야 한다.

사례	이미 가진 강점	DARI의 선택
Tarjimly AI + human language access	난민 대상 통번역 네트워크, AI 초벌번역, 인간 수정 data loop. FirstPass는 평균 3배 속도 향상을 제시한다.[3]	일반 번역과 인력망으로 경쟁하지 않고 고위험 항목의 전문 검수 파트너로 연동한다.
Signpost / IRAP information & support	현지화된 정보, 양방향 상담, 지원 서비스 연결과 community trust.[4]	정보 포털보다 개인 사건의 claim, 수정과 문서 변환 계보에 집중한다.
UNHCR RiMAP grounded legal AI	1,424개 법률 문서, 200여 국가, article-level citation과 법률가 검증.[5]	외부 법률 지식과 지원자 사건 기록을 분리하고 각각 출처를 남긴다.
LegalServer case management	법률구조기관의 intake, 사건, 문서, 역할과 업무 흐름.	전체 CMS와 경쟁하지 않고 삽입 가능한 integrity layer와 export를 만든다.
docassemble document assembly	구조화 질문과 규칙을 이용한 법률 문서 자동 조립.	자유로운 사건 서술과 다국어 변환에서 claim provenance를 추가한다.
CoCounsel professional workflow	권위 콘텐츠, source attribution, Word와 case workflow 통합.[6]	모델보다 신뢰 자료와 업무흐름이 오래간다는 전략을 따른다.

점유할 수 있는 좁은 위치

한국 난민신청 과정에서 지원자의 원문 진술, 확인된 claim, 한국어 초안, 수정본과 최종본을 의미 단위로 연결하는 applicant-controlled integrity layer.

조사만으로 경쟁 부재를 증명한 것은 아니다. 실제 파트너 discovery와 pilot에서 이 위치의 수요와 지불 또는 채택 의사를 확인해야 한다.

경쟁하지 않음
범용 번역과 통역 marketplace

새로 만들지 않음
전체 case management system

통제하지 않음
법적 유불리와 신빙성 판단

[3] Tarjimly · [4] Signpost · [5] UNHCR · [6] Thomson Reuters

03 · TARGET ARCHITECTURE

v0.4 전체 구조

모델을 중심에서 빼고, 사건기록과 검토 결정을 지속되는 기준으로 둔다.



생성 전 예방

active confirmed claim과 문항별 contract만 사용해 문서를 만들고 문장마다 claim ID를 연결한다.

생성 뒤 검수

모든 생성, 제안 적용과 수동 편집 뒤 delta를 다시 계산하고 불확실한 항목만 사람에게 보낸다.

04 · MODULE CONTRACTS

각 모듈이 받는 것과 내보내는 것

Capture + Meaning Read-back

P0-P1

입력 모국어 발화, 문항, 첨부자료

출력 evidence span, episode, candidate claim, `confirmed/uncertain/corrected/withdrawn`

한 번의 checkbox 대신 사건별로 실제 의미를 다시 확인한다.

Evidence-linked Case Record

P2

입력 read-back 결정, evidence, consent

출력 versioned active claim state와 접근·보관 정책

객관적 진실이 아니라 사용자가 확인한 현재 의도를 보존한다.

Controlled Artifact Builder

P3

입력 active claims, Semantic Contract, model adapter

출력 문장, claim IDs, model/version, unresolved items

허용된 사실에서 문서를 만들고 근거 없는 표현을 예방한다.

Semantic Delta + Assurance

P4-P5

입력 기준 claim, artifact revision, calibration

출력 `added/removed/changed/unclear`, pass/review/escalate

규칙, flat claim, 선택적 graph, 독립 검수 순으로 올린다.

Evidence Review + Export

P6-P7

입력 양쪽 evidence, plain-language delta, reviewer role

출력 결정, 최종 문서, portable packet, 제한된 receipt

원시 대화와 폐기 이력은 기본 export에서 제외한다.

Model & Evaluation Control Plane

C0-C2

입력 candidate model, frozen cases, ecological set

출력 regression scorecard, threshold, release decision

새 모델은 자동 채택하지 않고 shadow evaluation을 거친다.

Assurance Cascade

1 규칙
coverage
숫자·날짜
철회 값

→

2 Flat claim
누락·추가
direct judge

→

3 Micrograph
행위자
전언·순서

→

4 독립 검사
다른 계열
다른 경로

→

5 사람
중요하고
불확실한 것

동일 모델의 self-check와 자동 역번역은 독립 검증으로 계산하지 않는다.

05 · PRODUCT REALITY CHECK

현재 코드에서 먼저 고쳐야 할 세 가지 단절

새로운 detector보다 현재 사용자 흐름에서 provenance가 끊기는 지점을 먼저 해결해야 한다.

1 · 확인

전체 fact를 한 번에 확인한다

현재 fact 화면은 하나의 checkbox로 모든 항목을 confirmed 처리한다. 중요한 사건별 행위자, 시점, 확실성, 직접 경험 또는 전언을 사용자가 실제로 확인했다는 근거가 약하다.

수정 방향 episode 카드마다 모국어 read-back과 `맞음 / 불확실 / 정정 / 철회`를 제공하고 언어, 주체, 방법, revision을 기록한다.

2 · 수정

직접 고친 문장은 원문 근거와 다시 연결되지 않는다

현재 UI도 이 제한을 명시한다. 제안 적용과 수동 편집은 새 누락, 추가, 정정 전 값 재등장을 만들 수 있다.

수정 방향 모든 편집 직후 문장별 claim coverage와 semantic delta를 재계산한다. unresolved 항목은 export 전에 해결하거나 명시적으로 보류한다.

3 · 최종 이해

모든 대상 언어 사용자가 한국어 최종본을 확인하기 어렵다

현재 meaning view는 영어 사용자 경로에 치우쳐 있다. 지원자가 최종 한국어 문장의 의미를 자기 언어로 확인할 수 없다면 user-confirmed provenance라는 주장도 약해진다.

수정 방향 각 최종 문장에 source-language read-back, 연결 episode, `맞음 / 다름 / 판단 어려움`을 제공하고 고위험 항목은 인간에게 이관한다.

첫 verification boundary

초안 생성 → 제안 적용/직접 수정 → final Korean export

후속 확장

이 경계가 통과된 뒤 source-to-fact와 Korean-to-multilingual 단계를 각각 추가한다.

안전 관련 방향 변경

`유리하게 강화/불리하게 약화` 분류는 제품 core에서 제거한다. `added/removed/changed/unclear`와 evidence만 보여주며, 법률적 판단은 허가된 조력자에게 넘긴다.

검증은 finding F1보다 최종 case export로 평가한다

2×2 핵심 실험

	검수 없음 / direct judge	provenance-aware review
자유 생성	**B1/B3** 최신 frontier 직접 생성과 source-linked judge	**A1** 자유 생성 + DARI delta gate
controlled generation	**P1** Claim Ledger + Semantic Contract	**P2/P4** 제약 생성 + evidence review + 사람 routing

이 구조는 개선이 생성 전 예방, detector, evidence UI 중 어디에서 왔는지 분리한다.

1차 지표

1. **최종 export 100건당**
   남은 critical/high 의미 오류
2. **Reviewer-hour당**
   실제로 방지한 중요 오류
3. **Acceptable export까지**
   필요한 사람 검토 시간

반드시 함께 보는 guardrail

- 오류 없는 문서당 false alert
- 정상 문장의 불필요 수정률
- 철회된 claim 재등장률
- provenance coverage
- abstention과 unresolved rate
- 언어별, 오류 유형별 risk-coverage

모델 발전 내성

Model A
개발
threshold 고정

→

Model B
다른 family
holdout

→

Model C
새 version
shadow run

→

On-device
privacy 조건
별도 calibration

Value Persistence Curve

$V(m) = \text{residual_error}(\text{baseline } m) - \text{residual_error}(\text{DARI } m)$

$T(m) = \text{review_time}(\text{baseline } m) - \text{review_time}(\text{DARI } m)$

두 번의 주요 model upgrade에서 V와 T가 모두 실질적으로 0이면 별도 verifier를 축소한다. Case Record와 lineage의 가치는 별도로 평가한다.

07 · MOAT & SCENARIOS

해자는 기술 한 개가 아니라 검증 가능한 flywheel이다

1 사용자 확인
claim + exact evidence

→

2 실제 검토
수락·거절·수정 결정

→

3 안전한 label
동의·비식별 outcome

→

4 calibration
언어·오류별 threshold

→

5 더 적은 부담
필요한 것만 사람에게

원시 난민 진술 자체는 데이터 해자로 삼지 않는다. 학습에는 별도 동의와 최소화된 `claim - delta - evidence - decision` label을 사용한다.

시나리오 A

대부분의 검수가 범용화

생성기와 verifier의 차별성은 사라진다.

남길 것 claim 확인, lineage, export receipt.
중단 이것도 기관 가치가 없으면 검증 제품을 종료.

시나리오 B

취약 조건은 계속 남음

저자원 언어, 전언, 불확실성, 긴 서술에서 오류가 지속된다.

전략 전체 검사보다 고위험 문항과 취약 조건에 선택적으로 검수 배분.

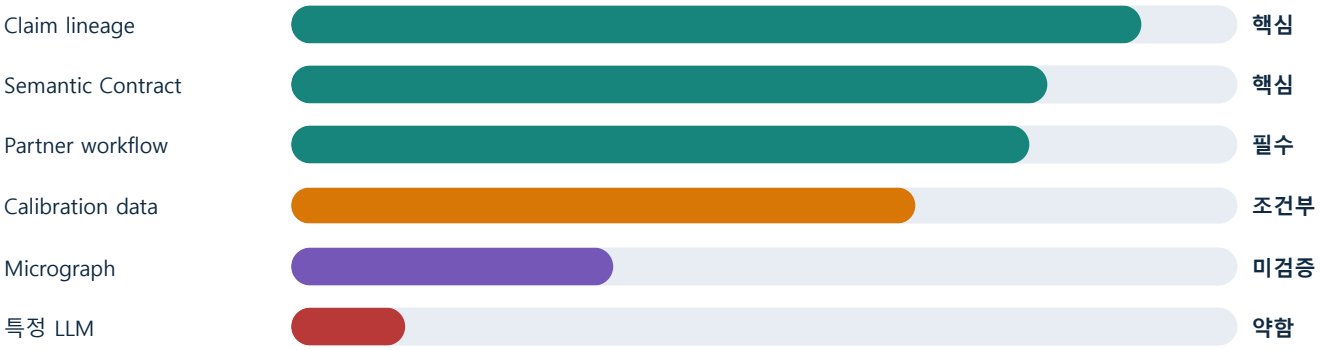
시나리오 C

privacy와 책임성 강화

cloud 사용이 어렵고 기관이 동의와 감사 기록을 요구한다.

전략 작은 모델을 안전하게 쓰는 calibration과 사람 이관이 핵심.

해자 후보의 증명 조건



객관적 점수

8/10
사용자 가치 잠재력

8/10
LLM 발전 내성 잠재력

5/10
현재 서비스 준비도

4/10
현재 검출 차별성

08 · DECISION GATES

성공 기준과 실행 순서

GO

- 같은 검토 부담에서 잔존 중요 오류 25% 이상 감소
- 또는 같은 잔존 오류에서 검토 시간 20% 이상 감소
- 두 언어와 두 model family에서 효과 방향 유지
- provenance 95% 이상

PIVOT

- verifier 이점은 작지만 lineage가 검토나 인계를 개선
- case record, read-back, export와 review receipt에 집중
- graph 추가 recall 8%p 미만이면 runtime에서 제거

KILL

- 최신 source-linked baseline과 비열등
- evidence UI도 시간 또는 정확도를 개선하지 못함
- partner가 portable record를 사용하지 않음
- 두 model upgrade에서 효과 소멸

권장 12주 실행 순서

1-2주 — **평가 계약과 위험 taxonomy 고정**

case export gold, 중요한 delta, normal variation, 사람 이관 기준을 조력자와 정의한다.

3-4주 — **episode read-back과 claim state prototype**

일괄 checkbox를 대체하고 확인 언어, 주체, revision을 기록한다.

5-6주 — **수정 후 delta gate**

제안 적용과 직접 편집 뒤 coverage, 철회 claim, unsupported addition을 다시 검사한다.

7-8주 — **작은 frozen benchmark**

자연 오류와 최소 대조쌍으로 current UI, frontier, direct judge, DARI를 비교한다.

9-10주 — **조력자 crossover pilot**

잔존 오류, review time, wrong correction과 evidence 사용 여부를 측정한다.

11-12주 — **Go, Pivot, Kill 결정**

graph를 추가하기 전 evidence workflow 자체가 실질적 효과를 보였는지 판단한다.

> **가장 먼저 만들 것은 더 복잡한 graph가 아니라, 수정 뒤에도 근거 연결이 유지되는 최종 export 경로다.**

09 · EVIDENCE & LIMITATIONS

근거와 해석 범위

[1] Stanford AI Index 2025
hai.stanford.edu/ai-index/2025-ai-index-report
고정 성능 수준에서 추론 비용이 빠르게 하락하고 소형 모델이 개선되는 흐름.

[2] WMT25 Automated Translation Evaluation
aclanthology.org/2025.wmt-1.24
segment와 span 오류 검출, precision-recall 균형과 언어 다양성의 지속적인 어려움.

[3] Tarjimly FirstPass
tarjimly.org/firstpass-landing
AI 초벌번역과 인간 수정, 난민 언어 data feedback loop.

[4] Signpost
signpost.ngo/home
커뮤니티 기반 다국어 정보와 양방향 지원.

[5] UNHCR RiMAP
unhcr.org/innovation/project/rimap-ai-virtual-assistant-refugee-law-support-protection
권위 있는 법률 자료, article-level citation과 법률가 검증.

[6] Thomson Reuters CoCounsel Legal
legal.thomsonreuters.com/en/legal/draft-review-analysis-corp
신뢰 콘텐츠, source attribution과 end-to-end 법률 workflow.

ACES and SPAN-ACES
aclanthology.org/2025.cl-1.4
평균 점수보다 오류 현상별 challenge set과 source-sensitive 평가가 필요함.

LegalServer Intake
legalserver.org/features/intake
법률구조기관의 intake와 case management workflow.

docassemble
docassemble.org
구조화 질문을 이용한 document assembly.

C2PA Explainer
spec.c2pa.org/.../Explainer.html
provenance가 이력을 설명하지만 내용의 진실성을 보장하지는 않는다는 구분.

프로젝트 내부 근거

- DARI 기획서(26.10.08)
- 검증시스템자료조사
- 현재 `capacitor-web/src/App.tsx` 사용자 흐름
- `local_verification_server.py`의 기존 검증 prompt
- verification v0.3 문서와 46개 contract/demo test

현재 주장할 수 없는 것

- DARI가 최신 model보다 정확하다는 주장
- graph가 flat claim보다 우수하다는 주장
- 실제 지원자가 workflow를 이해한다는 주장
- 법률적 타당성 또는 진술의 진실성 보장
- 민감한 correction data가 자동으로 해자가 된다는 주장

최종 판단

DARI가 장기적으로 가질 수 있는 기술적 가치는 모델보다 잘 쓰는 데 있지 않다. **사용자가 확인한 의미를 모델과 문서 사이에서 잃지 않고, 사람이 필요한 곳만 검토하며, 그 결과를 안전하게 인계하는 구조**에 있다.

이 구조도 최신 baseline과 실제 조력자 pilot을 이기지 못하면 축소하거나 중단한다.