# DARI 검증 시스템

# 왜 이 구조인가, 각 모듈은 무엇을 주고받는가

기획서와 자료조사, 현재 experiment/verification 구현을 연결해 설명한 아키텍처 이해 보고서

| | |
|---|---|
| 핵심 질문 | 서로 다른 언어의 두 문단이 같은 사건, 인물, 역할, 확실성, 정보 출처를 보존하는가? |
| 핵심 해법 | 두 문단을 각각 작은 사건 graph로 만들고, 같은 의미 단위를 정렬한 뒤 typed rule로 차이를 비교한다. |
| 현재 상태 | M1은 사람이 작성한 oracle graph stub, M2-M6는 실행 가능한 deterministic demo다. |
| 제품 경계 | 현재 DARI 서비스와 분리된 연구용 sidecar이며 사용자 데이터를 수정하지 않는다. |

## 한 문장 요약

**DARI는 번역을 점수 하나로 평가하지 않고, 의미를 구조화한 뒤 어떤 관계가 어떻게 달라졌는지를 실제 원문 구절과 함께 보고하는 시스템이다.**

## 작성 근거

DARI 기획서(2026-10-08), 검증시스템 자료조사(2026-10-05), ARCHITECTURE.md, GRAPH_METHOD.md, TEST_PLAN.md, graph pipeline demo 구현을 종합했다.

# 1. 문제에서 설계로

DARI 사용자는 번역 대상 언어를 충분히 읽기 어렵다. 따라서 '번역 품질 82점'만 보여줘서는 어떤 내용을 고쳐야 하는지 판단하기 어렵다. 필요한 것은 오류의 위치, 의미 유형, 양쪽 근거다.

| 제품 문제 | 설계 결정 | 이유 |
| --- | --- | --- |
| 사용자가 번역문을 직접 검수하기 어려움 | finding마다 source/translation evidence span 저장 | 사용자가 모국어 근거와 번역 근거를 함께 확인할 수 있음 |
| 행위자 교체나 전언 삭제는 단어가 비슷해도 위험 | event-role graph와 typed comparison | 표면 유사도보다 ACTOR, TARGET, REPORTS, certainty를 직접 비교 |
| parser/model 실패가 '문제 없음'으로 보일 수 있음 | failure를 indeterminate로 분리 | 빈 finding과 실행 실패를 구분 |
| 실험 결과의 원인을 알기 어려움 | extract, validate, align, diff, confirm 모듈 분리 | 어느 단계가 병목인지 개별 평가 가능 |
| 민감한 자료를 다룸 | 제품과 분리된 read-only sidecar, on-device 우선 | 원문 수정과 외부 전송을 최소화 |

## 설계의 중심 원칙

- 원문과 번역문을 서로 보지 않은 채 독립적으로 graph로 만든다.
- 문자열 유사도는 정렬 후보를 찾는 보조 수단으로만 사용한다.
- 행위자, 부정, 확실성, 출처, 시간은 discrete type으로 비교한다.
- 모든 판단은 실제 텍스트 span에 연결한다.
- 모델이 없는 oracle test부터 시작해 comparator 자체가 맞는지 먼저 확인한다.

# 2. 어떤 연구 아이디어를 가져왔는가

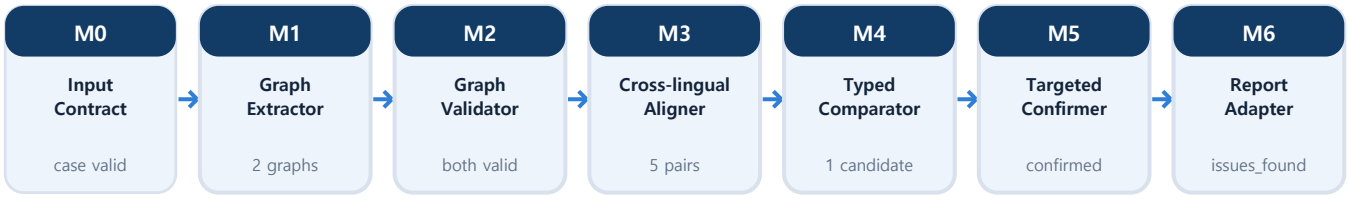
이 아키텍처는 한 논문을 그대로 구현한 것이 아니다. 번역 품질 평가, semantic role, meaning graph, graph alignment, QA 평가의 아이디어를 DARI 문제에 맞게 축소하고 조합했다.

| 연구 | 가져온 아이디어 | DARI에서의 위치 | 그대로 쓰지 않은 이유 |
|---|---|---|---|
| CometKiwi (Rei et al., 2022), xCOMET (Guerreiro et al., 2024) | reference-free QE, word/error span, severity | QE baseline과 report 표현 | 관계형 오류를 graph보다 명시적으로 설명하기 어려움 |
| MEANT (Lo and Wu, 2013), PropBank | predicate와 semantic role을 비교 | Event, ACTOR, TARGET, RECIPIENT | 언어별 SRL 품질과 문서 수준 coreference가 병목 |
| AMR, Smatch | 의미를 node-edge graph로 표현하고 정렬 후 triple 비교 | DocumentGraph와 alignment/diff 분리 | full AMR은 초기 범위와 다국어 비용이 큼 |
| S2MATCH (Opitz et al., 2020), FGW | node 의미와 graph 구조를 함께 고려한 soft alignment | M3의 장기 soft candidate score | 현재 gold pair가 적어 학습형 matcher를 쓰기 이름 |
| FactBank, TimeBank, PDTB | factuality, temporal relation, discourse/causal relation | certainty, evidentiality, BEFORE, CAUSES | 초기에는 위험 유형만 선별해 작은 schema로 사용 |
| QuestEval (Scialom et al., 2021) | 질문-답변으로 정보 보존 확인 | M5가 의심 edge만 국소 재확인 | 전체 문서 QA는 비용과 질문 생성 오류가 큼 |

## 중요한 구분

QE 논문은 경쟁 baseline과 오류 span 표현에 영향을 주었다. 핵심 DARI graph schema는 MEANT/PropBank/AMR 계열, 정렬은 Smatch/S2MATCH/FGW 계열, 국소 재확인은 QuestEval 계열의 아이디어에 더 가깝다. 하지만 현재 구현은 이 모델들을 아직 호출하지 않는다.

# 3. 전체 흐름




## 두 종류의 입력과 두 종류의 출력

| 구분 | 내용 |
|---|---|
| 입력 | source 문단, translation 문단, 언어 코드, case ID, revision/context |
| 중간 표현 | 각 문단의 DocumentGraph: Entity/Event/Value node, role/relation edge, scoped qualifier, evidence span |
| 비교 결과 | candidate diff: 어떤 semantic unit의 어떤 type이 달라졌는지와 양쪽 evidence |
| 최종 결과 | VerificationReport: status, confirmed finding, severity, evidence, provenance, errors |

## 왜 7개 모듈로 나누는가

- M1이 틀렸는지, M3 정렬이 틀렸는지, M4 규칙이 틀렸는지를 분리해서 측정할 수 있다.
- extractor나 aligner 모델을 교체해도 뒤쪽 계약을 유지할 수 있다.
- 실패한 단계와 실제 의미 변화가 같은 report에 섞이지 않는다.
- oracle graph를 사용하면 모델 없이 schema와 comparator의 타당성을 먼저 시험할 수 있다.

# 4. 모듈별 입출력과 역할

| 모듈 | Input | Output | 역할 | 현재 demo |
|---|---|---|---|---|
| M0 Input Contract | source/translation text, language, case ID | 검증된 VerificationCase | 빈 값, 언어, ID, schema를 확인하고 원문을 그대로 고정 | 실제 contract validator |
| M1 Graph Extractor | 한쪽 문단만 | DocumentGraph | Entity/Event/Value, edge, qualifier, evidence를 추출 | hand-authored fixture lookup stub |
| M2 Graph Validator | graph + 해당 원문 | valid/failure, counts, coverage | endpoint, qualifier, evidence offset, coverage를 검사 | 실제 deterministic validator |
| M3 Cross-lingual Aligner | source graph + translation graph | entity/value/event alignments, unmatched IDs | 같은 인물/사건/값을 1:1 또는 제한된 1:N으로 대응 | match_key oracle aligner |
| M4 Typed Comparator | 두 graph + alignments | typed candidate diffs | 역할, polarity, certainty, attribution, time을 규칙으로 비교 | 실제 deterministic rules |
| M5 Targeted Confirmer | candidate + local evidence | confirmed/rejected/abstained | 고위험 차이를 짧은 질문이나 사람 검토로 재확인 | scripted oracle decision |
| M6 Report Adapter | confirmed candidates | VerificationReport v1 | 중복을 병합하고 status/severity/evidence/provenance를 고정 | 실제 report pipeline |

## 현재 demo를 해석할 때의 주의

M2-M6의 계약과 규칙은 실제 코드로 실행된다. 그러나 M1은 사람이 작성한 정답 graph를 돌려주는 stub이고, M3은 사람이 넣은 match_key를 사용하며, M5는 미리 정한 결정표를 사용한다. 따라서 현재 결과는 'graph를 자동으로 잘 만들었다'는 증거가 아니라 '올바른 graph가 주어졌을 때 비교 구조가 의도대로 동작한다'는 증거다.

# 5. DocumentGraph 안에는 무엇이 들어가는가

| 요소 | 예시 | 왜 필요한가 |
|---|---|---|
| Entity node | Minsu, police, Sujin, home | 언어가 달라도 동일 인물을 정렬하기 위한 anchor |
| Event node | PARTICIPATE, SEARCH, REPORT, RETURN, MOVE | 문장의 핵심 사건을 비교 단위로 만듦 |
| Value node | May 3, FOLLOWING_DAY, duration | 날짜와 수치를 정규화해 표기 차이와 값 차이를 분리 |
| Role edge | ACTOR, TARGET, RECIPIENT | 누가 누구에게 무엇을 했는지 보존 |
| Event relation | REPORTS, BEFORE, CAUSES | 정보 출처, 시간, 인과 구조를 보존 |
| Qualifier | polarity, certainty, evidentiality | 부정과 가능성, 직접 경험/전언을 특정 event에 붙임 |
| Evidence span | document, start, end, quote | 모든 구조와 finding을 실제 텍스트에 연결 |
| Coverage | parsed_character_ratio, unparsed_spans | 분석하지 못한 부분을 '정상'으로 오해하지 않게 함 |

## 왜 5W1H 표 하나로 끝내지 않는가

5W1H slot은 한 사건을 간단히 요약하기 좋다. 그러나 문단에는 여러 사건, 전언 구조, 같은 인물의 반복 지칭, 사건 간 순서가 있다. graph는 사건마다 역할과 qualifier를 붙이고 사건끼리 REPORTS/BEFORE 같은 edge로 연결할 수 있어 문단 비교에 더 적합하다.

## 왜 full AMR을 그대로 쓰지 않는가

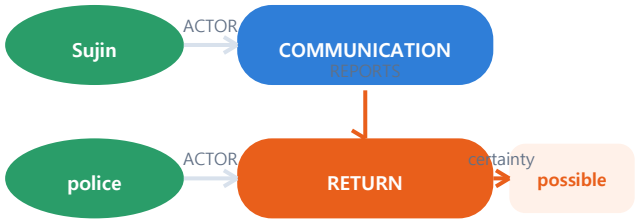
DARI의 목표는 모든 의미 현상을 표현하는 것이 아니라, 난민 신청서 번역에서 위험한 변화 유형을 안정적으로 찾는 것이다. 작은 domain graph는 annotation 비용과 다국어 parser 의존성을 줄이고, 각 차이를 명시적인 finding type으로 연결하기 쉽다.

# 6. 문단 사례로 보는 실제 실행

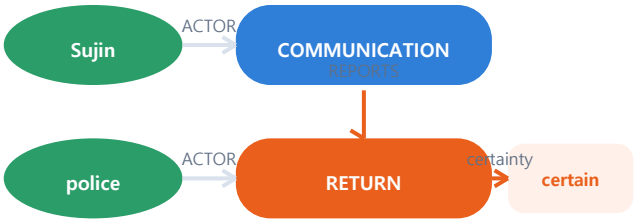
Source: 5월 3일 민수는 광장 시위에 참여했다. 시위가 끝난 뒤 경찰관 두 명이 그의 집을 수색했다. 이웃 수진은 경찰이 다시 올 수도 있다고 민수에게 말했다. 다음 날 민수는 다른 도시로 이동했다.

Translation: On May 3, Minsu joined a protest in the square. After it ended, two police officers searched his home. Sujin told Minsu that the police would definitely return. The next day, Minsu moved to another city.

**Source graph**




**Translation graph**




| 단계 | 이 사례에서 나온 결과 | 해석 |
|---|---|---|
| M1 | 각 graph 13 nodes, 14 edges, 15 qualifiers | 다섯 사건과 인물/장소/시간, 역할과 certainty를 구조화 |
| M2 | source valid, translation valid | 모든 element가 실제 문단 span에 연결되고 필수 qualifier 존재 |
| M3 | 5 event alignments, 모두 1:1 | PARTICIPATE, SEARCH, REPORT, RETURN, MOVE가 대응 |
| M4 | certainty_shift 후보 1건 | RETURN의 possible이 certain으로 바뀜 |
| M5 | confirmed | '다시 올 수도'와 'definitely return' 근거가 정확히 존재 |
| M6 | issues_found, finding 1건 | 정보 출처 Sujin은 보존되고 확실성만 변화 |

# 7. 세 가지 핵심 설계 결정

## 결정 1. 두 문단을 독립적으로 추출

source extractor에는 source만, translation extractor에는 translation만 보낸다. 두 문단을 동시에 보고 graph를 만들면 translation의 오류를 source에 맞춰 보정해 버릴 수 있다. independent extraction은 이런 leakage를 줄이고 각 언어 extractor의 성능을 따로 측정하게 한다.

## 결정 2. embedding은 정렬 후보에만 사용

police officer와 경찰처럼 표면이 다른 표현은 multilingual embedding이 도움이 된다. 그러나 possible과 certain, before와 after, actor와 target은 문맥상 비슷한 단어여도 의미가 반대일 수 있다. 따라서 M3에서 soft candidate를 찾고, M4에서는 discrete relation과 qualifier를 규칙으로 비교한다.

## 결정 3. 전체 문서를 다시 LLM judge에 맡기지 않고 국소 재확인

M4가 찾은 위험 edge만 M5가 질문으로 확인한다. 예를 들어 '원문과 번역문에서 경찰이 다시 올 가능성의 강도가 같은가?'처럼 좁은 질문을 사용한다. 이는 QuestEval의 QA 기반 정보 보존 아이디어를 좁혀 적용한 것으로, 비용과 환각 범위를 줄이고 evidence를 선명하게 만든다.

| 잘못된 단순화 | 왜 위험한가 | DARI의 대응 |
|---|---|---|
| 문장 embedding cosine 하나 | 역할 반전과 부정 반전에도 높을 수 있음 | 정렬과 판정을 분리 |
| 전체 graph similarity 점수 하나 | 어떤 관계가 바뀌었는지 설명하기 어려움 | typed diff와 evidence span |
| LLM judge 한 번 | model/prompt 변화와 malformed output | strict contract, local confirmer, provenance |
| parser 실패를 빈 finding으로 처리 | 사용자가 정상으로 오해 | indeterminate 상태 |

# 8. 현재 구현과 목표 구현

| 영역 | 현재 실행 가능 | 다음 구현 |
|---|---|---|
| 입력 계약 | strict VerificationCase | 제품 revision/digest gate 연결 |
| Graph 추출 | 사람이 만든 oracle fixture | multilingual LLM 또는 SRL/parser adapter, gold graph 평가 |
| Graph 검증 | endpoint, qualifier, evidence, coverage 검사 | event_graph.schema.json 고정 |
| 정렬 | match_key oracle, 1:1/1:N | hard anchor + multilingual soft alignment |
| 비교 | actor, certainty, attribution, temporal rule | 전체 v1 taxonomy와 ablation |
| 재확인 | scripted oracle | local QA model 또는 사람 검토 |
| Baseline | 설계만 존재 | CometKiwi/xCOMET, direct judge adapter |
| 평가 | 4 demo, 46 contract tests | bilingual pilot, extraction/alignment/oracle/end-to-end 분리 평가 |

## 성능을 증명하는 올바른 순서

- 1) Gold graph pair로 M4 Oracle comparison을 먼저 측정한다.
- 2) Source gold + Target predicted, Source predicted + Target gold로 언어별 extractor 병목을 분리한다.
- 3) 양쪽 predicted graph로 end-to-end 성능을 측정한다.
- 4) 같은 test pair에서 QE baseline, direct judge, domain_graph, graph_confirmed를 비교한다.
- 5) type별 precision/recall/F1, faithful false-positive rate, evidence span F1, indeterminate 비율을 함께 보고한다.

## 이 분해가 중요한 이유

Oracle도 낮으면 schema 또는 comparator 문제다. Oracle은 높지만 end-to-end가 낮으면 extractor/aligner 문제다. 최종 F1 하나만 보면 이 두 실패를 구분할 수 없다.

# 9. 연구 출처와 DARI 적용

| Citation | Paper | URL | DARI에 준 아이디어 |
|---|---|---|---|
| Rei et al. (2022) | COMET-22 / CometKiwi | https://aclanthology.org/2022.wmt-1.52/ | reference-free QE baseline |
| Guerreiro et al. (2024) | xCOMET | https://aclanthology.org/2024.tacl-1.54/ | sentence score + error span + severity |
| Lo and Wu (2013) | MEANT | https://aclanthology.org/W13-2254/ | predicate/argument semantic frame comparison |
| Palmer et al. (2005) | The Proposition Bank | https://aclanthology.org/J05-1004/ | predicate-argument role inventory |
| Banarescu et al. (2013) | Abstract Meaning Representation | https://aclanthology.org/W13-2322/ | node-edge meaning graph |
| Cai and Knight (2013) | Smatch | https://aclanthology.org/P13-2131/ | variable alignment and triple matching |
| Opitz et al. (2020) | S2MATCH | https://aclanthology.org/2020.tacl-1.34/ | soft semantic AMR matching |
| Scialom et al. (2021) | QuestEval | https://aclanthology.org/2021.emnlp-main.529/ | QA-based information preservation |
| Pustejovsky et al. (2003) | TimeBank | https://aclanthology.org/W03-0901/ | event/time relation annotation |
| Prasad et al. (2008) | Penn Discourse Treebank 2.0 | https://aclanthology.org/L08-1093/ | explicit/implicit discourse relations |
| Vayer et al. (2020) | Fused Gromov-Wasserstein | https://doi.org/10.3390/a13090212 | node feature + structural alignment candidate |

## 해석 원칙

위 연구가 DARI 문맥에서 성능 우위를 보장하는 것은 아니다. 각 논문에서 representation 또는 evaluation 아이디어를 가져왔고, 실제 우위는 DARI bilingual gold test에서 별도로 검증해야 한다.

# 10. 최종 이해 체크

| 질문 | 정확한 답 |
|---|---|
| 왜 graph인가? | 문장 표현이 달라도 사건과 역할을 같은 틀로 비교하고, 역할/출처/확실성 변화를 명시적으로 찾기 위해서다. |
| 왜 모델 없이 먼저 시험하는가? | 추출 모델의 오류와 graph schema/comparator의 오류를 분리하기 위해서다. |
| 모델은 언제 필요한가? | 처음 보는 문단을 자동 graph로 만들 때 필수에 가깝고, soft alignment와 confirmer에는 선택적으로 필요하다. |
| 현재 결과가 증명한 것은? | 정답 graph가 주어지면 validator, aligner, comparator, report가 의도한 계약으로 동작한다는 것. |
| 아직 증명하지 못한 것은? | 자유 문단 자동 추출 정확도와 실제 bilingual dataset에서 baseline보다 우수하다는 것. |
| 다음 핵심 실험은? | 5-10 gold graph pair 확대, M4 Oracle macro-F1, 이후 extractor adapter와 baseline 비교. |

## 아키텍처의 핵심 문장

**독립적으로 의미를 구조화하고, 조심스럽게 정렬하며, 관계와 속성을 typed rule로 비교하고, 의심되는 부분만 근거와 함께 다시 확인한다.**

---

본 보고서는 연구용 설계를 설명한다. 법적 판단, 사실성 판정, 난민 인정 가능성 판단을 수행하지 않는다.